

Objetivo: O conjunto de dados tem como objetivo analisar características demográficas, socioeconômicas e comportamentais de clientes (como idade, estado civil, profissão, experiência profissional, gastos e tamanho da família) para fins de segmentação de consumidores, permitindo identificar padrões de consumo e perfis de mercado úteis para estratégias de marketing e análise comportamental.

Número total de registros: 8068

Variáveis, seus tipos e valores faltantes:

Variável	Categoria	Valores Faltantes
Gender	Binária	0
Ever_Married	Binária	140
Age	Numérica Contínua	0
Graduated	Binária	78
Profession	Categórica nominal	124
Work_Experience	Numérica Discreta	829
Spending_Score	Categórica ordinal	0
Family_Size	Numérica Discreta	335
Var_1	Categórica ordinal	76
Segmentation	Categórica nominal	0







Provável mecanismo: Os valores faltantes parecem seguir predominantemente o mecanismo MAR (Missing At Random), pois a ausência de informações apresenta relação com outras variáveis observadas. Por exemplo, a ausência de experiência profissional ocorre majoritariamente em indivíduos mais jovens.

Valores duplicados: A verificação de duplicatas foi realizada utilizando a coluna identificadora (ID), sendo encontrados apenas dois registros duplicados.

Inconsistências:

- **Indivíduos classificados como engenheiro, advogado ou médico sem graduação registrada, o que pode indicar erro de preenchimento ou ausência de informação.**
- **Profissionais com 8 a 14 anos de experiência com idade inferior a 25 anos, sugerindo inconsistência temporal.**
- **Ausência de informação sobre estado civil principalmente em indivíduos entre 18 e 22 anos, possivelmente associada à idade.**
- **Profissões ausentes em indivíduos não graduados.**
- **Registros de executivos muito jovens (18–25 anos) com pouca experiência profissional.**

Outliers:



A análise exploratória das variáveis numéricas indicou presença significativa de outliers extremos.

Estratégias de tratamento propostas:

- **ever_married, graduated e profession = exclusão de registros, pois são poucos, além disso é impossível excluir a coluna inteira ou imputar, visto que as duas primeiras são colunas binárias e a última é categórica que poderia ter um imput por moda, mas não faz sentido.**
- **Outra alternativa: Ever_married / Graduated = imputar moda, e Profession = imputar categoria “Unknow”**
- **Work_experience e Family_size = Imputar por mediana, visto que possuem outliers.**
- **Var_1 é uma coluna sem descrição e irrelevante = Exclusão da coluna.**

A análise exploratória revelou alguns padrões interessantes mesmo antes da aplicação de modelos analíticos, a seguir serão compartilhadas algumas dessas descobertas:

- Observa-se tendência de **famílias maiores estarem associadas à segmentação D**, especialmente quando o tamanho da família é superior a três membros.
- Profissionais **sem graduação registrada apresentam, em média, maior tempo de experiência profissional**, sugerindo possíveis inconsistências ou trajetórias profissionais alternativas.
- A profissão **Advocacia apresenta a maior idade média entre as profissões analisadas**, sendo também observada maior idade média entre indivíduos do gênero masculino.
- A **segmentação A concentra maior número de artistas**, seguida por profissionais das áreas de entretenimento, engenharia, advocacia e executivos.
- A **segmentação C apresenta maior frequência de gastos médios a altos**, sugerindo maior poder de consumo nesse grupo.
- De forma geral, **a maioria das famílias apresenta spending score baixo.**
- Falta experiência de trabalho principalmente em pessoas mais jovens (18 a 23 anos) .
- Todos que **não possuem experiência de trabalho** ou não responderam **possuem gastos baixos (Low).**

Normalização:

A escolha da técnica de normalização foi baseada na análise da distribuição dos dados por meio de boxplots, permitindo identificar assimetria e presença de outliers, o que orientou a seleção da técnica mais adequada para cada variável.

Age:

- Poucos outliers (88 – 87).
- Outliers não agressivos.
- Distribuição quase simétrica.
- Interpretação: existem pessoas idosas (não é erro).
- Método: Min-Max.

A variável Age apresenta distribuição aproximadamente simétrica, com poucos valores extremos que representam casos reais (indivíduos mais idosos). Dessa forma, não há evidência de outliers agressivos, sendo adequada a aplicação de normalização Min-Max para preservar a escala dos dados.

Work_experience:

- Muitos outliers (10 – 11 – 12 – 13 – 14).
- Outliers agressivos.
- Distribuição assimétrica com cauda longa.
- Interpretação: pessoas podem ter mais de 10 anos de experiência em uma profissão = não é erro.
- Método: Logarítmica.

A variável Work_Experience apresenta distribuição assimétrica à direita, com concentração de valores baixos e presença de valores elevados, caracterizando uma cauda longa. Nesse caso, a aplicação de **transformação logarítmica** é recomendada para **reduzir a assimetria** e **minimizar o impacto dos valores extremos**.

Family_size:

- Poucos outliers (7 – 8 – 9).
- Outliers não agressivos.
- Distribuição quase simétrica.
- Interpretação: famílias grandes existem = não é erro.
- Método: Min-Max.

A variável Family_Size apresenta leve assimetria à direita, com presença de alguns valores mais elevados, porém plausíveis. Como os outliers não são extremos, pode-se aplicar normalização Min-Max, mantendo a interpretabilidade dos valores.