

RELATÓRIO TÉCNICO

Análise Exploratória de Dados

Segmentação de Clientes

Elaborado por

Joaquim Jonkel Magalhães Melo Junior

Dataset: segmentação de consumidores · 8.068 registros · 10 variáveis

1 Visão Geral do Dataset

O conjunto de dados tem como objetivo analisar características demográficas, socioeconômicas e comportamentais de clientes — incluindo idade, estado civil, profissão, experiência profissional, gastos e tamanho da família — para fins de segmentação de consumidores. Os resultados permitem identificar padrões de consumo e perfis de mercado úteis para estratégias de marketing e análise comportamental.

8.068

Registros Totais

10

Variáveis

2

Duplicatas Encontradas

1.1 Inventário de Variáveis

Variável	Tipo	Categoria	Val. Faltantes
Gender	Binária	Demográfica	0
Ever_Married	Binária	Demográfica	140
Age	Numérica Contínua	Demográfica	0
Graduated	Binária	Socioeconômica	78
Profession	Categórica Nominal	Socioeconômica	124
Work_Experience	Numérica Discreta	Socioeconômica	829
Spending_Score	Categórica Ordinal	Comportamental	0
Family_Size	Numérica Discreta	Demográfica	335
Var_1	Categórica Ordinal	Desconhecida	76
Segmentation	Categ. Nominal (alvo)	Alvo	0

2 Qualidade dos Dados

2.1 Valores Faltantes

A tabela abaixo consolida os valores faltantes por variável, incluindo o percentual em relação ao total de registros (8.068).

Variável	Qtd.	% Total	Observação
Work_Experience	829	10,3%	Concentrada em indivíduos de 18–23 anos
Family_Size	335	4,2%	Distribuição dispersa
Ever_Married	140	1,7%	Ausência frequente em jovens de 18–22 anos
Profession	124	1,5%	Presente em indivíduos não graduados
Graduated	78	1,0%	Possível omissão de resposta
Var_1	76	0,9%	Variável sem descrição funcional

Variável	Qtd.	% Total	Observação
Gender	0	0,0%	Completo
Age	0	0,0%	Completo
Spending_Score	0	0,0%	Completo
Segmentation	0	0,0%	Completo — variável alvo

Mecanismo de ausência (MAR — Missing At Random): Os valores faltantes apresentam relação com outras variáveis observadas. O exemplo mais evidente é Work_Experience, ausente majoritariamente em indivíduos de 18–23 anos — a lacuna é explicada pela variável Age, caracterizando o mecanismo MAR.

2.2 Registros Duplicados

A verificação de duplicatas foi realizada utilizando a coluna identificadora ID. Foram encontrados 2 registros duplicados (< 0,03% do total) — impacto negligenciável, mas que devem ser removidos para garantir integridade analítica.

2.3 Inconsistências Identificadas

Inconsistência	Variáveis Envolvidas	Provável Causa
Engenheiros, advogados ou médicos sem graduação registrada	Profession + Graduated	Erro de preenchimento ou dado ausente
Profissionais com 8–14 anos de experiência e menos de 25 anos de idade	Work_Experience + Age	Inconsistência temporal / dado incorreto
Ausência de estado civil predominantemente em jovens de 18–22 anos	Ever_Married + Age	Dado não coletado nessa faixa etária
Profissão ausente em indivíduos não graduados	Profession + Graduated	Dependência lógica entre variáveis
Executivos muito jovens (18–25 anos) com pouca experiência profissional	Profession + Age + Work_Exp.	Possível erro de classificação profissional

3 Análise de Outliers

A análise das variáveis numéricas foi realizada por meio de boxplots, permitindo identificar assimetria, dispersão e presença de valores extremos. As três variáveis numéricas foram avaliadas individualmente.

Variável	Min	Mediana	Média	Max	Outliers Detectados	Classificação
Age	18	40	43,47	90	87, 88	Não agressivos — idosos reais
Work_Experience	0	2	2,37	14	10, 11, 12, 13, 14	Agressivos — cauda longa
Family_Size	1	3	2,73	9	7, 8, 9	Não agressivos — famílias grandes reais

3.1 Age

- Distribuição aproximadamente simétrica.
- Outliers nos valores 87 e 88 — representam idosos reais, não erros.
- Poucos valores extremos, sem impacto significativo na distribuição.
- Intervalo observado: 18–90 anos.

3.2 Work_Experience

- Distribuição assimétrica à direita (cauda longa), com concentração de valores baixos.
- Outliers nos valores 10 a 14 anos — embora plausíveis, inflam a média.
- Maioria dos registros possui 0–4 anos de experiência.
- Requer transformação logarítmica para normalização.

3.3 Family_Size

- Distribuição com leve assimetria à direita.
- Outliers nos valores 7, 8 e 9 — famílias grandes existem (casos reais).
- Concentração entre 1 e 4 membros.
- Outliers não são agressivos; normalização Min-Max é adequada.

4 Estratégias de Tratamento Propostas

Com base na natureza de cada variável e no volume de dados faltantes, foram avaliadas as estratégias de tratamento mais adequadas. A tabela abaixo apresenta as opções consideradas e a recomendação final.

Variável	Estratégia Recomendada	Alternativa	Justificativa
Ever_Married	Exclusão de registros	Imputação pela moda	Poucos registros (1,7%); variável binária dificulta imputação segura
Graduated	Exclusão de registros	Imputação pela moda	Poucos registros (1,0%); variável binária
Profession	Exclusão de registros	Imputar categoria 'Unknown'	Variável nominal — imputação pela moda não é semanticamente válida
Work_Experience	Imputação pela mediana	—	Presença de outliers agressivos torna a média não representativa
Family_Size	Imputação pela mediana	—	Distribuição assimétrica; mediana é mais robusta que a média
Var_1	Exclusão da coluna	—	Variável sem descrição funcional; irrelevante para a análise

Nota sobre duplicatas: Os 2 registros duplicados identificados pelo campo ID foram removidos antes de qualquer etapa de imputação ou modelagem, preservando a unicidade dos registros e a integridade do conjunto de dados.

4.1 Critérios de Decisão

- Exclusão de registros: Volume pequeno de faltantes (<2%) + variável binária ou nominal sem substituto semântico adequado.
- Imputação pela mediana: Variável numérica com outliers ou distribuição assimétrica; mediana é mais robusta que a média nesses casos.
- Imputação pela moda: Variável binária/nominal com faltantes moderados e distribuição modal clara.
- Exclusão de coluna: Variável sem descrição funcional e sem correlação relevante com a variável-alvo.
- Imputar 'Unknown': Variável categórica com faltantes onde a ausência em si pode ser informativa.

5 Principais Descobertas da EDA

A análise exploratória revelou padrões relevantes antes mesmo da aplicação de modelos analíticos. As descobertas estão agrupadas por tema.

5.1 Padrões por Segmento

Segmento	Descoberta Principal
A	Concentra o maior número de artistas, seguida por profissionais de entretenimento, engenharia, advocacia e executivos.
C	Apresenta maior frequência de gastos médios a altos, sugerindo maior poder de consumo nesse grupo.
D	Associado a famílias maiores (mais de 3 membros), que tendem a se concentrar neste segmento.

5.2 Padrões Demográficos e Comportamentais

Experiência vs. Escolaridade

Profissionais sem graduação registrada apresentam, em média, maior tempo de experiência profissional — sugerindo possíveis inconsistências nos dados ou trajetórias profissionais alternativas (ex.: progressão sem diploma formal).

Idade por Profissão e Gênero

A profissão Advocacia apresenta a maior idade média entre as profissões analisadas. Indivíduos do gênero masculino também apresentam maior idade média em comparação ao gênero feminino.

Gastos Gerais

A maioria das famílias apresenta Spending Score baixo (Low). Este padrão é especialmente marcante entre indivíduos sem experiência profissional registrada — todos nesse grupo possuem gastos classificados como Low.

Faixa Etária e Experiência

A ausência de Work_Experience concentra-se em indivíduos de 18 a 23 anos, corroborando o mecanismo MAR identificado na análise de valores faltantes.

6 Normalização das Variáveis Numéricas

A escolha da técnica de normalização foi orientada pela análise da distribuição dos dados via boxplots, avaliando simetria, presença de outliers e interpretação contextual dos valores extremos.

Variável	Distribuição	Outliers	Interpretação	Método	Justificativa
Age	Aproximadamente simétrica	Poucos, não agressivos (87–88)	Idosos reais	Min-Max	Preserva escala; outliers não distorcem o intervalo
Work_Experience	Assimétrica à direita	Muitos, agressivos (10–14)	Alta experiência é possível, mas rara	Logarítmica	Reduz assimetria e minimiza impacto dos extremos
Family_Size	Levemente assimétrica à direita	Poucos, não agressivos (7–9)	Famílias grandes existem	Min-Max	Mantém interpretabilidade; outliers são plausíveis

6.1 Referência Técnica dos Métodos

- Normalização Min-Max: Reescala os valores para o intervalo [0, 1] com base nos valores mínimo e máximo observados: $x' = (x - \min) / (\max - \min)$. Recomendada para distribuições simétricas sem outliers agressivos, pois preserva as relações proporcionais entre os valores.
- Transformação Logarítmica: Aplica o logaritmo natural sobre os valores: $x' = \log(x + 1)$. Indicada para distribuições com forte assimetria à direita e cauda longa, pois comprime os valores altos e aproxima a distribuição da normalidade.

Variáveis categóricas e binárias (Gender, Ever_Married, Graduated, Profession, Spending_Score, Segmentation) não são submetidas a normalização numérica. Variáveis binárias recebem codificação 0/1 direta; variáveis nominais requerem One-Hot Encoding; variáveis ordinais podem ser codificadas com Label Encoding preservando a ordem.